

ANÁLISIS DE HURTOS EN BOGOTÁ
(INFORME)

Universidad EAN

DataXperience – G6 C3

David Esteban Salgado Forero

Juan Jerónimo Noel Martín

Carlos Andrés León Palomino

Fran Sebastian Quiroga Cuellar

Camila Silva Gómez

13 de septiembre de 2026

1. PLANTEAMIENTO DEL PROBLEMA Y OBJETIVO DEL PROYECTO.

Pregunta problema estructurada.

¿Cómo se ha comportado la incidencia del delito de hurto por modalidades en la ciudad de Bogotá D.C. durante el periodo comprendido entre 2023 y 2025, y cuáles son los patrones temporales y espaciales más críticos identificados a través del análisis de datos?

Preguntas de apoyo del proyecto.

1. ¿Cuáles son las tres modalidades de hurto más frecuentes en Bogotá durante el periodo 2023-2025?
2. ¿Existe una diferencia significativa en la cantidad de hurtos reportados entre las distintas localidades de Bogotá (ej. norte vs. sur)?
3. ¿Qué días de la semana y meses registran los picos más altos de criminalidad según los datos reportados?
4. ¿Cuál es el género y grupo etario de las víctimas más afectado en los hurtos de la ciudad?
5. ¿Qué porcentaje de los hurtos reportados utiliza algún tipo de arma o medio específico frente a los que no especifican?

Objetivo.

Investigar, estructurar, comprender y responder a las preguntas base planteadas anteriormente.

2. BÚSQUEDA Y OBTENCIÓN DE LOS DATOS (FUENTE Y JUSTIFICACIÓN).

Para la obtención de datos necesarios investigamos directamente en una de las páginas del estado, específicamente (y también referenciada en el cap. 12):

https://www.datos.gov.co/Seguridad-y-Defensa/Reporte-Hurto-por-Modalidades-Polic-a-Nacional/9vha-vh9n/about_data

En donde conseguimos un archivo publico csv con los reportes de hurto en el país del 1 de enero de 2010 asta el 31 de marzo de 2026 (momento en el que realizamos la posterior descarga) este archivo proviene se la DIJIN – Policía Nacional.

Es de especificar que este se actualiza cada cierto tiempo, por lo que al momento de revisar la página es posible que encuentre que el archivo contenga nuevos datos, razón por la cual nuestra investigación abarca hasta el ya mencionado mes de marzo del año actual.

3. COMPRENSIÓN DEL CONJUNTO DE DATOS Y DESCRIPCIÓN DE LAS VARIABLES.

El conjunto de datos proviene del reporte oficial de la Policía Nacional denominado o nombrado: *Reporte_Hurto_por_Modalidades_Policía_Nacional_20260831.csv*. Contiene originalmente 633,804 registros organizados en 9 columnas:

- **Departamento:** nombre del departamento donde ocurrió el hecho (ej. Cesar, Atlántico, Bogotá).
- **Municipio:** nombre del municipio o ciudad específica (ej. Chiriguaná, soledad, Bogotá D.C.).
- **Código dane:** código numérico oficial asignado por el dane para identificar la entidad territorial.
- **Armas medios:** tipo de arma o medio utilizado en el hurto (ej. No reportado, arma de fuego, cortopunzante, etc.).
- **Fecha hecho:** fecha en la que ocurrió el incidente (formato día/mes/año).
- **Genero:** género de la víctima o involucrado.
- **Grupo etario:** clasificación por rango de edad de la víctima o involucrado (ej. Adultos).
- **Tipo de hurto:** tipificación legal o modalidad del hurto según la norma (ej. Artículo 239. Hurto entidades comerciales).
- **Cantidad:** cantidad numérica de eventos o elementos reportados en el registro.

4. PROCESO COMPLETO DE LIMPIEZA Y PREPARACIÓN DE LOS DATOS.

Diagnóstico de Calidad.

- **Duplicados:** Se identificaron 247,603 filas completamente duplicadas (representando el 39.06% del total de registros iniciales).
- **Valores Nulos:**
 - *Municipio:* 1 valor nulo (0.000158%).
 - *Grupo etario:* 56,625 valores nulos (8.93%).
 - *Género:* 571,958 valores nulos (90.24%).

Ejecución de la limpieza.

1. **Eliminación de duplicados:** se usó *df.drop_duplicates()*, reduciendo la base de 633,804 a 386,201 filas únicas.
2. **Tratamiento de nulos:**
 - Se imputó la categoría *no reportada* a los valores faltantes en *género* y *grupo etario* para evitar la pérdida masiva de filas en las demás columnas.
 - Se eliminó la única fila puntual que carecía de valor en *municipio*.
3. **Transformación de tipos de datos y filtrado:**
 - La columna *fecha hecho* se transformó al formato estándar de fecha (*datetime*).

- Se realizó un filtrado espacial seleccionando únicamente los registros correspondientes a Bogotá (*municipio* conteniendo “Bogotá”).
- Se extrajo la variable temporal *año* y se acotó el análisis espacial y temporal para Bogotá en el periodo 2023 a 2025, obteniendo una muestra final limpia de 8,873 registros.

5. ANÁLISIS EXPLORATORIO DE DATOS (EDA).

El análisis exploratorio documentado en el cuaderno se enfoca en la distribución temporal y frecuencia de los registros limpios en Bogotá D.C. para el periodo 2023–2025:

- **Visualización:** Se construyó un gráfico de barras utilizando *seaborn.countplot* con paleta de colores azul (*Blues_d*), donde se representó el conteo directo de registros por año con sus etiquetas de valor sobre cada barra.
- **Comportamiento Anual:**
 - En 2023 se registraron 1,704 eventos.
 - En 2024 el registro ascendió a 3,814 eventos.
 - En 2025 el registro fue de 3,355 eventos.

6. ANÁLISIS ESTADÍSTICO REALIZADO.

El cuaderno aplica un análisis estadístico descriptivo y de agregación focalizado en:

- **Frecuencias absolutas y relativas:** Conteo de duplicados, evaluación porcentual de valores faltantes por variable y totalización de eventos filtrados.
- **Agregación temporal:** Agrupación y ordenamiento por variable categórica ordinal (*año*) mediante *.value_counts().sort_index()*.
- **Análisis comparativo de tendencia:** Medición visual y cuantitativa de la variación año tras año en la frecuencia de hurtos reportados.

7. HALLAZGO DE PATRONES, RELACIONES E INSIGHTS.

- **Alta duplicidad en datos origen:** Cerca del 39% de los registros iniciales eran réplicas exactas, lo cual resalta la importancia de la fase de des duplicado antes de cualquier toma de decisiones.
- **Subregistro en variables demográficas:** La variable *genero* presentó un subregistro severo del 90.24%, lo que indica que esta columna no es confiable para realizar perfilamiento de víctimas sin una recolección primaria adicional.
- **Pico de incidencia en 2024:** En Bogotá D.C., los registros limpios mostraron un crecimiento del **123.8% entre 2023 y 2024** (pasando de 1,704 a 3,814), seguido de una ligera estabilización o reducción hacia **2025 con 3,355 registros** (una disminución del 12.0% frente al año anterior).

8. SELECCIÓN DEL MODELO Y JUSTIFICACIÓN DE SU ELECCIÓN.

La Regresión Logística se seleccionó como el modelo supervisado más adecuado por las siguientes razones metodológicas y teóricas:

- **Naturaleza del Variable Objetivo (Binaria/Dicotómica):** Permite clasificar la probabilidad de un evento categórico discreto de interés (por ejemplo, determinar si un hurto involucra el uso de *armas/violencia* frente a *sin violencia/no reportado*, o si ocurre en una categoría de vulnerabilidad alta vs. baja).
- **Interpretabilidad Científica de los Coeficientes (Odds Ratios):** A diferencia de modelos del tipo "caja negra" (como Random Forest o Redes Neuronales), la Regresión Logística permite estimar y cuantificar directamente las **razones de probabilidad (Odds Ratios)** para cada variable independiente (tipo de arma/medio, horario, grupo etario, etc.). Esto facilita explicar a las autoridades de policía e instituciones públicas qué factores aumentan o disminuyen el riesgo relativo de ocurrencia del delito.
- **Eficiencia Computacional y Escalabilidad:** El dataset de la Policía Nacional cuenta con un volumen considerable de datos (cientos de miles de registros). La Regresión Logística es muy rápida de entrenar, converge eficientemente y no requiere capacidades computacionales prohibitivas.
- **Robustez Frente al Sobreajuste (Overfitting):** Al ser un modelo lineal en sus coeficientes logit, minimiza el riesgo de memorizar el ruido de la muestra de entrenamiento cuando se aplican técnicas de regularización (L1/L2).

9. APLICACIÓN DEL MODELO.

La aplicación del modelo dentro del flujo de trabajo de ciencia de datos consta de los siguientes pasos fundamentados:

Definición de Variables:

- **Variable Dependiente (Y):** Ocurrencia del tipo o modalidad de violencia/arma utilizada en el hurto (1 = Evento de alto impacto/violento, 0 = Evento de menor impacto/sin arma).
- **Variables Independientes ($X_1, X_2, \dots, X_k$):** Variables categóricas codificadas (mediante *One-Hot Encoding*) como *grupo etario* (adultos, menores, etc.), *género*, *armas medios*, *temporada/año (año)* y *ubicación/código dane*.

Preprocesamiento y Split de Datos:

- **Limpieza previa:** Imputación de nulos críticos (e.g., categorizar nulos como 'no reportado') y eliminación de registros duplicados.
- **División:** Segmentación del dataset filtrado (para Bogotá D.C.) en conjuntos de entrenamiento (e.g., 70%-80%) y prueba (e.g., 20%-30%) utilizando muestreo estratificado para conservar la proporción original de las clases.

10. EVALUACIÓN DEL MODELO E INTERPRETACIÓN DE LOS RESULTADOS.

1. Métricas de Rendimiento:

- **Exactitud (Accuracy):** Porcentaje general de clasificaciones correctas sobre la muestra de prueba.
- **Matriz de Confusión:** Permite desglosar las predicciones en Verdaderos Positivos (VP), Falsos Positivos (FP), Verdaderos Negativos (VN) y Falsos Negativos (FN).
- **Precisión y Sensibilidad (Recall):** La *Sensibilidad* evalúa la habilidad del modelo para detectar la totalidad de hurtos violentos/de alto riesgo, mientras que la *Precisión* mide cuántos de los identificados como críticos realmente lo eran.
- **Área bajo la Curva ROC (AUC-ROC):** Cuantifica la capacidad del modelo para discriminar entre ambas clases a través de diferentes umbrales de decisión.

2. Interpretación de los Coeficientes (β):

- Si un coeficiente $\beta_i > 0$ (*OddsRatio* > 1), esa característica (p. ej., horario nocturno o cierta modalidad) incrementa exponencialmente la probabilidad del evento.
- Si $\beta_i < 0$ (*OddsRatio* < 1), esa variable actúa como un factor disuasorio o reduce la probabilidad.

11. CONCLUSIONES Y RECOMENDACIONES.

Conclusiones

- La Regresión Logística demuestra ser un punto de partida (baseline) sólido y transparente para la modelación predictiva en seguridad pública.
- Ofrece explicabilidad directa respecto a qué variables (armas, tipo de hurto, grupos poblacionales) están asociadas estadísticamente a mayor severidad en los delictivos de Bogotá.
- El análisis exploratorio previo del dataset demuestra variaciones temporales marcadas entre los años 2023 y 2025 en Bogotá, lo que valida la necesidad de modelos cuantitativos dinámicos.

Recomendaciones

1. **Atención a la Calidad de los Datos de Origen:** Dado que un alto porcentaje de campos como *genero* o *grupo etario* presentan datos no reportados o vacíos en los registros policiales, se recomienda estandarizar el protocolo de captura en la denuncia para mejorar la precisión predictiva de los modelos.
2. **Uso de Términos de Interacción:** Incorporar interacciones entre variables (por ejemplo, *Horario* $\times$ *Localidad/Ubicación*) para capturar patrones espacio-temporales complejos.
3. **Manejo de Desbalanceo de Clases:** En caso de que la modalidad de interés sea infrecuente, aplicar técnicas de balanceo (*smote* o pesos de clase `class_weight='balanced'`) para priorizar la *Sensibilidad (Recall)* sobre la exactitud.

4. **Despliegue Orientado a la Toma de Decisiones:** Utilizar la salida de probabilidad estimada del modelo para orientar cuadrantes de patrullaje preventivo e intervenciones focalizadas de la Policía Metropolitana de Bogotá.

12. REFERENCIAS.

Policía Nacional de Colombia. (2026). *Reporte Hurto por Modalidades Policía Nacional* [Conjunto de datos]. Datos Abiertos Gobierno de Colombia.

https://www.datos.gov.co/Seguridad-y-Defensa/Reporte-Hurto-por-Modalidades-Polic-a-Nacional/6sqw-8cg5/about_data